



Redes Neurais Artificiais: *Perceptron* de Múltiplas Camadas

Prof.: Arismar Moraes Gonçalves Júnior

Engenharia da Computação

Universidade do Estado de Minas Gerais

Unidade Divinópolis


Divinópolis, Maio de 2026

1. Introdução
2. Princípio de Funcionamento
3. Treinamento
 - Backpropagation*
 - Terminologia
 - Equações para Ajuste dos Pesos
4. Pseudocódigos

- ▶ Redes Perceptron de Multiplas Camadas (PMC):
 - ▶ Possuem pelo menos uma camada intermediária (escondida) de neurônios;
 - ▶ Implementação possibilitada no final dos anos 1980;
 - ▶ Algoritmo de aprendizado *Backpropagation* (1986)¹.
- ▶ Características:
 - ▶ Arquitetura *feedforward*;
 - ▶ Treinamento supervisionado;
 - ▶ Possibilidade de aplicação em diversos tipos de problemas:
 - ▶ Aproximação universal de funções;
 - ▶ Reconhecimento/classificação de padrões (inclusive em problemas não-linearmente separáveis);
 - ▶ Identificação e controle de processos;
 - ▶ Previsão de séries temporais;
 - ▶ Otimização de sistemas.

¹Rumelhart *et al*, 1986. *Parallel Distributed Processing*.


► Ilustração de uma rede PMC:




- ▶ Cada uma das entradas da rede é propagada em direção à camada de saída;
- ▶ As saídas da primeira camada escondida são as entradas da segunda camada, e assim sucessivamente;
- ▶ A camada de saída pode ser composta por diversos neurônios, os quais representam as saídas do processo a ser mapeado;
- ▶ No PMC, o comportamento entrada/saída do problema em questão está distribuído nas camadas intermediárias.

- ▶ Treinamento:
 - ▶ Processo de ajuste dos pesos da rede;
 - ▶ Baseado em um conjunto de p amostras/observações do processo a ser mapeado;
 - ▶ Realizado de forma supervisionada (para cada amostra dos sinais de entrada, conhece-se a respectiva saída/resposta desejada (d));
 - ▶ Efetuado por meio do algoritmo *Backpropagation*, também denominado Regra Delta Generalizada.


- ▶ Fase *Forward* (propagação adiante):
 - ▶ Os sinais $x_1, x_2, \dots, x_n$ são propagados, camada a camada, até a produção das saídas;
 - ▶ Esta fase visa somente a obtenção das resposta da rede, não sendo os pesos/limiares ajustados.
- ▶ Fase *Backward* (propagação reversa):
 - ▶ As saídas produzidas pela rede são comparadas com as saídas desejadas, gerando sinais de erro;
 - ▶ Ajustes nos pesos/limiares de todos os neurônios.





- ▶ $W_{ji}^{(L)}$ são matrizes de pesos entre o j -ésimo neurônio da camada L e o i -ésimo neurônio da camada $L - 1$:
 - ▶ $W_{ji}^{(3)}$ é o peso da conexão entre o j -ésimo neurônio da camada de saída e o i -ésimo neurônio da camada 2;
 - ▶ $W_{ji}^{(2)}$ é o peso da conexão entre o j -ésimo neurônio da camada 2 e o i -ésimo neurônio da camada 1;
 - ▶ $W_{ji}^{(1)}$ é o peso da conexão entre o j -ésimo neurônio da camada 1 e o i -ésimo neurônio da camada de entrada.

- ▶ Lembrando que cada um dos neurônios realiza a agregação das entradas, sendo este resultado o argumento da função de ativação (que deve ser contínua e diferenciável no PMC):



- ▶ $I_j^{(L)}$ são vetores cujos elementos denotam a entrada ponderada do j -ésimo neurônio da camada L :

$$I_j^{(1)} = \sum_{i=0}^n W_{ji}^{(1)} \cdot x_i \Leftrightarrow I_j^{(1)} = W_{1,0}^{(1)} \cdot x_0 + W_{1,1}^{(1)} \cdot x_1 + \dots + W_{1,n}^{(1)} \cdot x_n \quad (5.1)$$

$$I_j^{(2)} = \sum_{i=0}^{n_1} W_{ji}^{(2)} \cdot Y_i^{(1)} \Leftrightarrow I_j^{(2)} = W_{1,0}^{(2)} \cdot Y_0^{(1)} + W_{1,1}^{(2)} \cdot Y_1^{(1)} + \dots + W_{1,n_1}^{(2)} \cdot Y_{n_1}^{(1)} \quad (5.2)$$

$$I_j^{(3)} = \sum_{i=0}^{n_2} W_{ji}^{(3)} \cdot Y_i^{(2)} \Leftrightarrow I_j^{(3)} = W_{1,0}^{(3)} \cdot Y_0^{(2)} + W_{1,1}^{(3)} \cdot Y_1^{(2)} + \dots + W_{1,n_2}^{(3)} \cdot Y_{n_2}^{(2)} \quad (5.3)$$


- ▶ $Y_j^{(L)}$ são vetores cujos elementos denotam a saída do j -ésimo neurônio da camada L :

$$Y_j^{(1)} = g(I_j^{(1)}) \quad (5.4)$$

$$Y_j^{(2)} = g(I_j^{(2)}) \quad (5.5)$$

$$Y_j^{(3)} = g(I_j^{(3)}) \quad (5.6)$$

- ▶ Exemplo da terminologia adotada para uma rede PMC:
 - ▶ Duas entradas x_1 e x_2 ($n = 2$), três neurônios na primeira camada escondida ($n_1 = 3$), dois na segunda camada escondida ($n_2 = 2$) e um na camada de saída ($n_3 = 1$);
 - ▶ Função de ativação tangente hiperbólica ($\tanh$).



► Matrizes de pesos:

$$W_{ji}^{(1)} = \begin{bmatrix} 0.2 & 0.4 & 0.5 \\ 0.3 & 0.6 & 0.7 \\ 0.4 & 0.8 & 0.3 \end{bmatrix} \quad W_{ji}^{(2)} = \begin{bmatrix} -0.7 & 0.6 & 0.2 & 0.7 \\ -0.3 & 0.7 & 0.2 & 0.8 \end{bmatrix} \quad W_{ji}^{(3)} = [0.1 \quad 0.8 \quad 0.5]$$

► Vetores $I_j^{(1)}$ e $Y_j^{(1)}$, para $x_1 = 0,3$ e $x_2 = 0,7$:

$$I_j^{(1)} = \begin{bmatrix} I_1^{(1)} \\ I_2^{(1)} \\ I_3^{(1)} \end{bmatrix} = \begin{bmatrix} W_{1,0}^{(1)} \cdot x_0 + W_{1,1}^{(1)} \cdot x_1 + W_{1,2}^{(1)} \cdot x_2 \\ W_{2,0}^{(1)} \cdot x_0 + W_{2,1}^{(1)} \cdot x_1 + W_{2,2}^{(1)} \cdot x_2 \\ W_{3,0}^{(1)} \cdot x_0 + W_{3,1}^{(1)} \cdot x_1 + W_{3,2}^{(1)} \cdot x_2 \end{bmatrix} = \begin{bmatrix} 0.2 \cdot (-1) + 0.4 \cdot 0.3 + 0.5 \cdot 0.7 \\ 0.3 \cdot (-1) + 0.6 \cdot 0.3 + 0.7 \cdot 0.7 \\ 0.4 \cdot (-1) + 0.8 \cdot 0.3 + 0.3 \cdot 0.7 \end{bmatrix} = \begin{bmatrix} 0.27 \\ 0.37 \\ 0.05 \end{bmatrix}$$

$$Y_j^{(1)} = \begin{bmatrix} Y_1^{(1)} \\ Y_2^{(1)} \\ Y_3^{(1)} \end{bmatrix} = \begin{bmatrix} g(I_1^{(1)}) \\ g(I_2^{(1)}) \\ g(I_3^{(1)}) \end{bmatrix} = \begin{bmatrix} \tanh(0.27) \\ \tanh(0.37) \\ \tanh(0.05) \end{bmatrix} = \begin{bmatrix} 0.26 \\ 0.35 \\ 0.05 \end{bmatrix} \xrightarrow{Y_0^{(1)} = -1} Y_j^{(1)} = \begin{bmatrix} Y_0^{(1)} \\ Y_1^{(1)} \\ Y_2^{(1)} \\ Y_3^{(1)} \end{bmatrix} = \begin{bmatrix} -1 \\ 0.26 \\ 0.35 \\ 0.05 \end{bmatrix},$$

- Vetores $I_j^{(2)}$ e $Y_j^{(2)}$:

$$I_j^{(2)} = \begin{bmatrix} I_1^{(2)} \\ I_2^{(2)} \end{bmatrix} = \begin{bmatrix} W_{1,0}^{(2)} \cdot Y_0^{(1)} + W_{1,1}^{(2)} \cdot Y_1^{(1)} + W_{1,2}^{(2)} \cdot Y_2^{(1)} + W_{1,3}^{(2)} \cdot Y_3^{(1)} \\ W_{2,0}^{(2)} \cdot Y_0^{(1)} + W_{2,1}^{(2)} \cdot Y_1^{(1)} + W_{2,2}^{(2)} \cdot Y_2^{(1)} + W_{2,3}^{(2)} \cdot Y_3^{(1)} \end{bmatrix} = \begin{bmatrix} 0.96 \\ 0.59 \end{bmatrix}$$

$$Y_j^{(2)} = \begin{bmatrix} Y_1^{(2)} \\ Y_2^{(2)} \end{bmatrix} = \begin{bmatrix} g(I_1^{(2)}) \\ g(I_2^{(2)}) \end{bmatrix} = \begin{bmatrix} \tanh(0.96) \\ \tanh(0.59) \end{bmatrix} = \begin{bmatrix} 0.74 \\ 0.53 \end{bmatrix} \xrightarrow{Y_0^{(2)} = -1} Y_j^{(2)} = \begin{bmatrix} Y_0^{(2)} \\ Y_1^{(2)} \\ Y_2^{(2)} \end{bmatrix} = \begin{bmatrix} -1 \\ 0.74 \\ 0.53 \end{bmatrix}$$

- Vetores $I_j^{(3)}$ e $Y_j^{(3)}$ da camada de saída:

$$I_j^{(3)} = \begin{bmatrix} I_1^{(3)} \end{bmatrix} = \begin{bmatrix} W_{1,0}^{(3)} \cdot Y_0^{(2)} + W_{1,1}^{(3)} \cdot Y_1^{(2)} + W_{1,2}^{(3)} \cdot Y_2^{(2)} \end{bmatrix} = [0.76]$$

$$Y_j^{(3)} = \begin{bmatrix} Y_1^{(3)} \end{bmatrix} = \begin{bmatrix} g(I_1^{(3)}) \end{bmatrix} = [\tanh(0.76)] = [0.64]$$

- ▶ Advém da propagação retrógrada do erro (E), da camada de saída para as camadas intermediárias, empregando o gradiente do erro (∇E) e determinada taxa de aprendizagem (η);
- ▶ Erro quadrático da k -ésima amostra de treinamento:

$$E(k) = \frac{1}{2} \sum_{j=1}^{n_3} \left(d_j(k) - Y_j^{(3)}(k) \right)^2$$

- ▶ Ajuste dos pesos da camada de saída²:

$$W_{ji}^{(3)} \leftarrow W_{ji}^{(3)} + \eta \cdot \delta_j^{(3)} \cdot Y_i^{(2)} \quad (5.15)$$

$$\delta_j^{(3)} = (d_j - Y_j^{(3)}) \cdot g'(I_j^{(3)}) \quad (5.17)$$

²O termo $\delta_j^{(3)}$ representa o gradiente local em relação ao j -ésimo neurônio da camada de saída

- Ajuste dos pesos da segunda camada escondida³:

$$W_{ji}^{(2)} \leftarrow W_{ji}^{(2)} + \eta \cdot \delta_j^{(2)} \cdot Y_i^{(1)} \quad (5.26)$$

$$\delta_j^{(2)} = - \left(\sum_{k=1}^{n_3} \delta_k^{(3)} \cdot W_{kj}^{(3)} \right) \cdot g'(I_j^{(2)}) \quad (5.28)$$

- Ajuste dos pesos da primeira camada escondida:

$$W_{ji}^{(1)} \leftarrow W_{ji}^{(1)} + \eta \cdot \delta_j^{(1)} \cdot X_i \quad (5.37)$$

$$\delta_j^{(1)} = - \left(\sum_{k=1}^{n_2} \delta_k^{(2)} \cdot W_{kj}^{(2)} \right) \cdot g'(I_j^{(1)}) \quad (5.39)$$

³Os termos $\delta_j^{(2)}$ e $\delta_j^{(1)}$ representam os gradientes locais em relação ao j -ésimo neurônio da segunda e primeira camada, respectivamente.

Início {Algoritmo PMC – Fase de Treinamento}

- <1> Obter o conjunto de amostras de treinamento $\{x^{(k)}\}$;
- <2> Associar o vetor de saída desejada $\{d^{(k)}\}$ para cada amostra;
- <3> Iniciar $w_{ji}^{(1)}$, $w_{ji}^{(2)}$ e $w_{ji}^{(3)}$ com valores aleatórios pequenos;
- <4> Especificar taxa de aprendizagem $\{\eta\}$ e precisão requerida $\{\varepsilon\}$;
- <5> Iniciar o contador de número de épocas $\{\acute{e}poca \leftarrow 0\}$;
- <6> Repetir as instruções:
 - <6.1> $E_M^{anterior} \leftarrow E_M$; {conforme (5.8)}
 - <6.2> Para todas as amostras de treinamento $\{x^{(k)}, d^{(k)}\}$, fazer:
 - <6.2.1> Obter $l_j^{(1)}$ e $y_j^{(1)}$; {conforme (5.1) e (5.4)}
 - <6.2.2> Obter $l_j^{(2)}$ e $y_j^{(2)}$; {conforme (5.2) e (5.5)}
 - <6.2.3> Obter $l_j^{(3)}$ e $y_j^{(3)}$; {conforme (5.3) e (5.6)}
 - <6.2.4> Determinar $\delta_j^{(3)}$; {conforme (5.15)}
 - <6.2.5> Ajustar $w_{ji}^{(3)}$; {conforme (5.17)}
 - <6.2.6> Determinar $\delta_j^{(2)}$; {conforme (5.26)}
 - <6.2.7> Ajustar $w_{ji}^{(2)}$; {conforme (5.28)}
 - <6.2.8> Determinar $\delta_j^{(1)}$; {conforme (5.37)}
 - <6.2.9> Ajustar $w_{ji}^{(1)}$; {conforme (5.39)}
 - ~~<6.3> Obter $y_j^{(3)}$ ajustado; {conforme 6.2.1, 6.2.2 e 6.2.3}~~
 - <6.4> $E_M^{atual} \leftarrow E_M$; {conforme (5.8)}
 - <6.5> $\acute{e}poca \leftarrow \acute{e}poca + 1$;
- Até que: $|E_M^{atual} - E_M^{anterior}| \leq \varepsilon$

$$E_M = \frac{1}{p} \sum_{k=1}^p E(k) \quad (5.8)$$

Fim {Algoritmo PMC – Fase de Treinamento}

Início {Algoritmo PMC – Fase de Operação}

- <1> Obter uma amostra $\{ \mathbf{x} \}$;
- <2> Assumir $W_{ji}^{(1)}$, $W_{ji}^{(2)}$ e $W_{ji}^{(3)}$ já ajustadas no treinamento;
- <3> Execute as seguintes instruções:
 - <3.1> Obter $I_j^{(1)}$ e $Y_j^{(1)}$; {conforme (5.1) e (5.4)}
 - <3.2> Obter $I_j^{(2)}$ e $Y_j^{(2)}$; {conforme (5.2) e (5.5)}
 - <3.3> Obter $I_j^{(3)}$ e $Y_j^{(3)}$; {conforme (5.3) e (5.6)}
- <4> Disponibilizar as saídas da rede, as quais são dadas pelos elementos contidos em $Y_j^{(3)}$

Passo
Forward

Fim {Algoritmo PMC – Fase de Operação}

- ▶ Silva, I. N.; Spatti, D. H.; Flauzino, R. A. Redes Neurais para engenharia e ciências aplicadas: fundamentos teóricos e aspectos práticos, Editora ArtLiber, 2^a edição, 2016;
- ▶ Haykin, S. Redes Neurais - Principios e Pratica, Bookman, 2^a edição, 2000;.