



Redes Neurais Artificiais: PMC - Aplicações e Aspectos Importantes

Prof.: Arismar Moraes Gonçalves Júnior

Engenharia da Computação

Universidade do Estado de Minas Gerais

Unidade Divinópolis


Divinópolis, Maio de 2026

1. Introdução
2. Aplicações
 - Aproximação de Funções
 - Reconhecimento de Padrões
3. Aspectos Importantes
 - Validação cruzada
 - Divisão dos subconjuntos de treinamento e teste
 - Underfitting* x *Overfitting*
 - Convergência
4. Implementação


- ▶ O *Perceptron* de Múltiplas Camadas (PMC) é o tipo de rede neural mais empregado em problemas de engenharia e ciências;
- ▶ Três principais aplicações:
 - ▶ Aproximação de funções;
 - ▶ Reconhecimento/classificação de padrões;
 - ▶ Sistemas dinâmicos (variantes no tempo).
- ▶ Além de uma adequada divisão dos dados de treinamento e validação, a topologia da rede deve ser cuidadosamente determinada.

- ▶ Mapeamento do comportamento de um processo, com base em diversas medições de suas entradas e saídas;
- ▶ Uma rede PMC com apenas 1 camada escondida é capaz de mapear qualquer função contínua no espaço das funções reais (teorema da aproximação universal de Kolmogorov (1957));
- ▶ Superposição de funções de ativação logística (ou tangente hiperbólica), ponderadas pelos pesos da rede.


$$y(x_1, x_2, \dots, x_n) = \sum_{i=1}^{n_1} \underbrace{\lambda_i}_{\text{parcela (i)}} \cdot \underbrace{g_i^{(1)}(u_i^{(1)})}_{\text{parcela (ii)}} \quad u_i^{(1)} = \sum_{j=1}^n W_{ji}^{(1)} \cdot x_j - \theta_i$$



► Exemplo:




► Combinação linear de funções de ativação logísticas:



- ▶ Consiste na associação de um padrão de entrada (amostra) para uma das classes previamente definidas;
- ▶ No caso binário:
 - ▶ Assinala-se valor 0 ao atributo “ausência”;
 - ▶ Atribui-se valor 1 ao atributo “presença”;
- ▶ O PMC pode ser aplicado a problemas não-linearmente separáveis:
 - ▶ Para padrões dispostos em regiões convexas¹, apenas 1 camada escondida;
 - ▶ Para regiões não-convexas, 2 camadas escondidas.
- ▶ O PMC pode ser aplicado em problemas com múltiplas classes.



¹ Do ponto de vista geométrico, região em que, todos os pontos contidos em quaisquer segmentos de reta, definidos por dois pontos delimitados pelo respectivo domínio, estiverem ainda dentro desta.

- Exemplo - Função booleana OU-exclusivo:




x_1	x_2	X_{OR}
0	0	$0 \rightarrow \odot$
0	1	$1 \rightarrow \otimes$
1	0	$1 \rightarrow \otimes$
0	1	$0 \rightarrow \odot$

- Exemplo - Função booleana OU-exclusivo:




- Exemplo - Ilustração da superfície de separabilidade:


Resultado do neurônio de saída (Y)



- ▶ Em regiões convexas, PMC com uma camada escondida e uma camada de saída:




- ▶ Em regiões não-convexas, PMC com 2 camadas escondidas e 1 camada de saída:




- ▶ Neurônios A, B e C → região convexa da esquerda;
- ▶ Neurônios D, E e F → região convexa da direita;
- ▶ Neurônios G e H → enquadramento das regiões;
- ▶ Neurônio Y → operação booleana OR;


- ▶ Em regiões desconexas (disjuntas), PMC com duas camadas escondidas:



- ▶ Para problemas com múltiplas classes, inclusão de mais neurônios na camada de saída do PMC;
- ▶ Método sequencial:
 - ▶ Com m neurônios na camada de saída o PMC é capaz de classificar 2^m classes;
 - ▶ Dificuldade no treinamento de problemas complexos.



- ▶ De outra forma, método *one of c-classes*:
 - ▶ Cada neurônio de saída corresponde a uma classe do problema;




Codificação *one of c-classes*


y_1	y_2	y_3	y_4	Classe
1	0	0	0	A
0	1	0	0	B
0	0	1	0	C
0	0	0	1	D

- ▶ A topologia do PMC é usualmente determinada de forma empírica, por meio do desempenho na validação cruzada;
- ▶ Considerando uma rede PMC com 1 camada escondida, treina-se as seguintes topologias candidatas, por exemplo:
 - ▶ Topologia candidata 1 $\rightarrow$ 5 neurônios;
 - ▶ Topologia candidata 2 $\rightarrow$ 10 neurônios;
 - ▶ Topologia candidata 3 $\rightarrow$ 15 neurônios;
 - ▶ Topologia candidata 4 $\rightarrow$ 20 neurônios.
- ▶ Então, verifica-se a aptidão frente a um conjunto de dados diferente daquele usado no ajuste dos parâmetros internos da rede;
- ▶ Dois diferentes métodos são utilizados:
 - ▶ Amostragem aleatória;
 - ▶ k -partições (*k-fold cross validation*).


- ▶ Entre 60 a 90% dos dados são aleatoriamente escolhidos para o subconjunto de treinamento;
- ▶ O restante fica alocado para o conjunto de teste/validação;
- ▶ A partição deve ser repetida diversas vezes (n ensaios);
- ▶ O desempenho global é utilizado na seleção da topologia.




- ▶ O conjunto total de amostras é dividido em k partições, sendo $(k - 1)$ destas empregadas no treinamento;
- ▶ A partição restante constitui o conjunto de teste/validação;
- ▶ As redes são treinadas k vezes (n^o ensaios = k);
- ▶ O desempenho global é utilizado na seleção da topologia.





- ▶ O PMC conhece o comportamento do processo a ser mapeado apenas nos seus domínios de definição;
- ▶ Deve ser assegurado que os valores *mín* e *máx* dos dados estejam contidos no subconjunto de treinamento.




- ▶ Subajuste (*underfitting*):
 - ▶ Número de neurônios insuficiente;
 - ▶ Erro quadrático elevado no treinamento e validação.
- ▶ O aumento indiscriminado do n^o de neurônios e/ou camadas escondidas não garantem a generalização;
- ▶ Sobreajuste (*overfitting*):
 - ▶ Memorização excessiva da rede;
 - ▶ Erro quadrático baixo no treinamento, mas elevado na validação.




► Ilustração do *overfitting* - função seno com ruídos:




- ▶ Para evitar as situações de *underfitting* e *overfitting*, parada antecipada na validação cruzada;
- ▶ O processo de aprendizagem é constantemente verificado pela aplicação do subconjunto de teste, sendo finalizado quando houver elevação do erro quadrático.




- ▶ A superfície de erro do PMC é não-linear, fato que pode ocasionar a convergência para mínimos locais;



- ▶ Para evitar:
 - ▶ Realizar o treinamento de cada topologia mais de uma vez;
 - ▶ Empregar métodos de otimização como o *simulated annealing*, algoritmos genéticos, dentre outros.



(a) Fase de Treinamento



(b) Fase de Operação

- ▶ Silva, I. N.; Spatti, D. H.; Flauzino, R. A. Redes Neurais para engenharia e ciências aplicadas: fundamentos teóricos e aspectos práticos, Editora ArtLiber, 2^a edição, 2016;
- ▶ Haykin, S. Redes Neurais - Principios e Pratica, Bookman, 2^a edição, 2000;.